

R para Ciência dos Dados - II

Primeira Parte

João Lopes e Pedro Sousa

Março 2026



Programa



Programa



- **Transformação dos dados**
- **Exploração dos dados**
- **Modelação**
- Relatórios e apresentações
- Comunicação



Programa



- **Transformação dos dados**

- Vetores numéricos
- Fatores
- Vetores lógicos

- **Exploração dos dados**

- Variação
- Valores em falta
- Covariação
- Padrões e Modelos

- **Modelação**


- Construir modelo simples
- Construir modelo com workflow()
- Construir vários modelos com workflow()



Recapitulação



» Esquema geral



H. Wickham M. Çetinkaya-Rundel & G. Grolemund (2023)

<https://r4ds.hadley.nz/>

<https://tidyverse.org/>



Dia 1 - Transformação



Horário	Tema
09:30 – 11:00	Introdução Vetores numéricos
11:15 – 12:30	Vetores numéricos (cont.)
14:00 – 15:00	Fatores
15:15 – 17:00	Vetores lógicos

Dia 1 - Transformação



▪ Vetores numéricos

- Contagens ----- (c/ exercícios)
- Transformações numéricas ----- (c/ exercícios)
- Transformações genéricas ----- c/ exercícios)

▪ Fatores

- Operações básicas
- Base de dados gss_cat ----- (c/ exercícios)
- Alterar ordem dos fatores ----- (c/ exercícios)
- Alterar os fatores ----- (c/ exercícios)

▪ Vetores lógicos

- Comparações ----- (c/ exercícios)
- Álgebra booleana ----- (c/ exercícios)
- Sumarização ----- (c/ exercícios)
- Transformações condicionais ----- (c/ exercícios)

Recapitulação



» Pacote **dplyr**

- `filter()` Selecionar linhas (i.e. observações);
- `arrange()` Ordenar linhas (i.e. observações);
- `select()` Selecionar colunas (i.e. variáveis);
- `mutate()` Criar novas colunas (i.e. variáveis);
- `summarize()` Calcular estatísticas descritivas.
- `group_by()` Criar grupos de observações para manipulação.

<https://dplyr.tidyverse.org/>

Recapitulação



» Pacote dplyr

```
library("tidyverse")

?diamonds

diamonds |>
  select(price, carat, cut) |>
  filter(carat < 3) |>
  mutate(lprice = log10(price)) |>
  group_by(cut) |>
  summarize(
    mean_lprice = mean(lprice),
    mean_carat = mean(carat)
  ) |>
  arrange(desc(mean_lprice))

#use data "diamonds"
#select "price", "carat" and "cut"
#filter for smaller diamonds
#create variable "lprice"
#group by "cut"
#calculate mean of "lprice"
#calculate mean of "carat"
#arrange by "mean_lprice"
```

Recapitulação



» Pacote dplyr

```
# A tibble: 5 × 3
  cut      mean_lprice mean_carat
<ord>      <dbl>      <dbl>
1 Fair      3.51      1.03
2 Premium   3.45      0.889
3 Good      3.41      0.847
4 Very Good 3.39      0.806
5 Ideal     3.32      0.702
```

Dia 2 - Exploração



Horário	Tema
09:30 – 11:00	Estatísticas descritivas Variação
11:15 – 12:30	Valores em falta
14:00 – 15:00	Covariação
15:15 – 17:00	Covariação (cont.) Padrões e modelos



Dia 2 - Exploração



- **Estatísticas descritivas** ----- (c/ exercícios)
- **Variação**
 - Valores típicos ----- (c/ exercícios)
 - Valores invulgares
- **Valores em falta**
 - Explícitos ----- (c/ exercícios)
 - Implícitos ----- (c/ exercícios)
 - Fatores e grupos vazios
- **Covariação**
 - Uma categórica e uma numérica ----- (c/ exercícios)
 - Duas categóricas ----- (c/ exercícios)
 - Duas numéricas ----- (c/ exercícios)
- **Padrões e modelos** ----- (c/ exercícios)

Recapitulação



» Pacote **ggplot2**

- Data;
- Aesthetic mapping (**aes**);
- Geometric object (**geom**);
- Statistical transformation (**stat**);
- Scale;
- Themes.

<https://ggplot2.tidyverse.org/>



Recapitulação



» Pacote ggplot2

```
set.seed(1984)

diamonds |>
  filter(carat < 3) |>
  slice_sample(n=500, by=cut) |>
  ggplot(aes(x=carat, y=price, color=cut)) +
  geom_point(alpha=0.1, size=1) +
  stat_smooth(
    method="lm",
    formula="y ~ x + I(x^2) + I(x^3)",
    se=FALSE) +
  scale_x_continuous(trans="log10") +
  scale_y_continuous(trans="log10") +
  labs(x="Weight", y="Price", color="Cut") +
  theme_minimal()
```


#use data "diamonds"
#filter for smaller diamonds
#sample for 500 obs per "cut"
#aesthetics mapping
#geometric object
#statistical transformation

#scale for x-axis
#scale for y-axis
#scale for labels
#change theme

Recapitulação



» Pacote ggplot2



Dia 3 - Modelação



Horário	Tema
09:30 – 11:00	Introdução Construir modelo simples
11:15 – 12:30	Construir modelo com <i>workflow</i>
14:00 – 15:00	Construir modelo com <i>workflow</i> (cont.) Construir vários modelos com <i>workflow</i>
15:15 – 17:00	Construir vários modelos com <i>workflow</i> (cont.) Informações finais



Dia 3 - Modelação



- **Construir modelo simples**
 - Explorar dados
 - Ajustar e avaliar modelo ----- (c/ exercícios)
 - Usar modelo para previsão ----- (c/ exercícios)
- **Construir modelo com *workflow***
 - Explorar dados
 - Dividir dados
 - Criar *workflow* ----- (c/ exercícios)
 - Ajustar modelo ----- (c/ exercícios)
 - Avaliar modelo ----- (c/ exercícios)
- **Construir vários modelos com *workflow***
 - Explorar dados
 - Dividir dados
 - Criar *workflow* e afinar modelo 1 ----- (c/ exercícios)
 - Criar *workflow* e afinar modelo 2 ----- (c/ exercícios)
 - Ajustar e avaliar o melhor modelo ----- (c/ exercícios)



Recapitulação



» Pacote **stats**: funções `lm()` e `summary()`

- Data;
- Formula (e.g. `formula()`);
- Fit model (eg. `lm()`, `glm()`, `aov()`, ...);
- Extract parameters (eg. `residuals()`, `predicted()`, `coef()`, ...);
- Testing assumptions (eg. `plot()`, ...);
- Evaluate model (eg. `summary()`, `AIC()`, `logLik()`, ...).

<https://www.tmwr.org>

<https://www.tidymodels.org/>





» Regressão linear simples


```
beta <- c(-1.6, 0.03)
tb_lm <- tibble(
  x = runif(20, min=18, max=60),
  y = beta[1] + beta[2]*x + rnorm(20, mean=0, sd=0.1)
)

res_lm <- lm(y ~ x, data=tb_lm)
tb_lm |>
  mutate(preds=predict(res_lm), resids=residuals(res_lm)) |>
  ggplot(aes(x=x, y=y)) +
  geom_point() +
  stat_smooth(method="lm", formula="y ~ x", se=FALSE, color="blue") +
  geom_segment(aes(xend=x, yend=preds), color="red")
```

Modelos



» Regressão linear simples






» Regressão linear múltipla

```
beta <- c(-1.6, 0.03, -1.0)
tb_lm2 <- tibble(
  x1 = runif(20, min=18, max=60),
  x2 = rbinom(20, size=1, prob=0.5),
  y = beta[1] + beta[2]*x1 + beta[3]*x2 + rnorm(20, mean=0, sd=0.1)
)
res_lm2 <- lm(y ~ x1 + x2, data=tb_lm2)
b <- coef(res_lm2)
tb_lm2 |>
  mutate(
    x2 = factor(x2), preds = predict(res_lm2), resid = residuals(res_lm2)
  ) |>
  ggplot(aes(x=x1, y=y, color=x2)) + geom_point() +
  geom_abline(slope=b[2], intercept=b[1], color="blue") +
  geom_abline(slope=b[2], intercept=sum(b[c(1, 3)]), color="blue") +
  geom_segment(aes(xend=x1, yend=preds), color="red")
```



» Regressão linear múltipla






» Regressão logística

```
beta <- c(-6, 0.15)
tb_glm <- tibble(
  x = runif(20, min=18, max=60),
  z = beta[1] + beta[2]*x,          # z = [-Inf, Inf]
  p_y = exp(z) / (1 + exp(z)),      # p_y = [0, 1]
  y = rbinom(20, size=1, prob=p_y) # y = {0, 1}
)

res_glm <- glm(y ~ x, binomial(link="logit"), data=tb_glm)
tb_glm |>
  mutate(preds = predict(res_glm, type="resp"), resid = residuals(res_glm)) |>
  ggplot(aes(x=x, y=y)) + geom_point() +
  stat_smooth(method="glm", formula="y ~ x", se=FALSE, color="blue",
    method.args=list(family="binomial")) +
  geom_segment(aes(xend=x, yend=preds), color="red")
```



» Regressão logística





» *Machine Learning: Dados*


```
beta <- c(-6, 0.25, -0.1)
tb_ml <- tibble(
  x1 = runif(40, min=18, max=60),
  x2 = runif(40, min=18, max=60),
  z = beta[1] + beta[2]*x1 + beta[3]*x2,
  p_y = exp(z) / (1 + exp(z)),
  y = factor(rbinom(40, size=1, prob=p_y))
)

tb_ml |>
  ggplot(aes(x=x1, y=x2, color=y)) +
  geom_point() +
  geom_abline(intercept=-beta[1]/beta[3], slope=-beta[2]/beta[3],
    linetype="dashed", color="darkgray")
```

Modelos



» *Machine Learning: Dados*





» *Machine Learning: Árvores de decisão*


```
library("rpart")
library("rpart.plot")

res_rf <- rpart(y ~ x1 + x2, data=tb_ml, method="class",
  control=rpart.control(
    minsplit=6, #minimum number of observations for a split
    minbucket=2, #minimum number of observations in a leaf
    maxdepth=30) #maximum depth of the tree
)
table(predict(res_rf, type="class"), tb_ml$y)
#    0  1
#0 22  2
#1  1 15

rpart.plot(res_rf, extra=101, digits=3, box.palette="RdBu")
```




» *Machine Learning: Árvores de decisão*



Modelos



» *Machine Learning*: Árvores de decisão





» *Machine Learning*: Redes neuronais

```
library("nnet")
library("NeuralNetTools")


res_nnet <- nnet(y ~ x1 + x2, data=tb_ml,
  size=1,      #number of units in hidden layer
  decay=0,    #weight decay
  maxit=100) #maximum number of iterations
table(predict(res_nnet, type="class"), tb_ml$y)
#    0  1
#0 21  0
#1  2 17

plotnet(res_nnet, bord_col="black", pos_col="black", neg_col="gray")
text(c(-0.15, 0.65), 0.9, round(res_nnet$wts[c(1, 4)], 1)) #Bias
text(-0.6, c(0.8, 0.2), round(res_nnet$wts[2:3], 1))      #Input
text(0.2, 0.6, round(res_nnet$wts[5], 1))                  #Hidden
```

Modelos




» *Machine Learning*: Redes neuronais



Modelos





» *Machine Learning*: Árvores de decisão



Avaliação de modelos




» Visão Geral



Avaliação de modelos




» Visão Geral



Avaliação de modelos



» Visão Geral



Avaliação de modelos




» Métricas: variável contínua

Root Mean Square Error (RMSE)

$$\text{RMSE} = \sqrt{\sum_{i=1}^n (\hat{y} - y)^2 / n}$$

Mean Absoute Error (MAE)

$$\text{MAE} = \sum_{i=1}^n |\hat{y} - y| / n$$



Avaliação de modelos




» Métricas: variável categórica (binária)

	Real	
Predicted	Positive (P.)	Negative (N.)
Positive	True P.	False P.
Negative	False N.	True N.

True Positive Rate (Sensitivity)
= TP/P

False Positive Rate (1 - Specificity)
= $FP/N = 1 - TN/N$

Trade-off: Sensitivity vs. Specificity



PRR
Plano de Recuperação
e Resiliência



**REPÚBLICA
PORTUGUESA**



Financiado pela
União Europeia
NextGenerationEU



Avaliação de modelos




» Métricas: variável categórica (binária)

	Real	
Predicted	Positive (P.)	Negative (N.)
Positive	True P.	False P.
Negative	False N.	True N.

True Positive Rate (Sensitivity)
= TP/P

False Positive Rate (1 - Specificity)
= $FP/N = 1 - TN/N$

Trade-off: Sensitivity vs. Specificity



M. Thoma (2018)

Informações finais



Informações finais



» Gestão de projectos


- Estrutura de pastas;
- Ficheiro README (e nomeação de ficheiros);
- Controlo de versões (e.g. github.com, gitlab.com, git.ine.pt).



Informações finais



» Estrutura de pastas



```
C:.\n├── Projects\n│   ├── 2023\n│   │   ├── 2023.01.01_ProjectName\n│   │   └── 2023.04.01_ProjectName\n│   ├── 2024\n│   │   ├── 2024.02.29_ProjectName\n│   │   └── 2024.12.25_ProjectName\n│   └── 2025\n│       ├── 2025.03.05_ProjectName\n│       └── 2025.10.31_DSR2025\n│           ├── bin\n│           ├── data\n│           ├── docs\n│           ├── media\n│           ├── results\n│           │   ├── 1.transform\n│           │   ├── 2.exploratory\n│           │   └── 3.modeling
```

Informações finais



» Ficheiro README

```
#autor:      Joao Sollari Lopes
#local:      INE, Lisboa
#criado:     31.12.2025
#modificado: 29.02.2026

+bin
  |0.examples.r           #exemplos para recapitulacao
  |0.install_packages.r   #instalar pacotes necessarios
  |1.transform.r          #transformacao de dados
  |2.exploration.r        #exploração de dados
  |3.modelling.r          #modelacao de dados

+docs
  |DSR-II2026_program.pdf  #programa
  |DSR-II2026_slides.pdf   #slides [versao final]
  |DSR-II2026_slides_20260101.pptx #slides [v2026-01-01]
  |DSR-II2026_slides_20260229.pptx #slides [v2026-02-29]

+results
  +1.tranform             #resultados de "1.transform.r"
  +2.exploration           #resultados de "2.exploration.r"
  +3.modelling            #resultados de "3.modelling.r"
README.txt               #Este ficheiro
```

Informações finais



» Controlo de versões

bin/3.modelling.r							
@@ -2,7 +2,7 @@							
2	#local:	INE, Lisboa		2	#local:	INE, Lisboa	
3	#Rversion:	4.3.1		3	#Rversion:	4.3.1	
4	#criado:	17.07.2023		4	#criado:	17.07.2023	
5	- #modificado:	18.04.2024		5	+ #modificado:	16.09.2024	
6				6			
7	# 0. INDEX			7	# 0. INDEX		
8	{			8	{		
@@ -344,7 +344,7 @@ lr_res >							
344	scale_x_log10(labels = scales::label_number())			344	scale_x_log10(labels = scales::label_number())		
345				345			
346	lr_res >			346	lr_res >		
347	- show_best("roc_auc", n = 5) >			347	+ show_best(metric = "roc_auc", n = 5) >		
348	arrange(penalty)			348	arrange(penalty)		
349				349			
350	lr_best <-			350	lr_best <-		

Informações finais



» Comunidade R

- <https://www.r-project.org/>
- <https://www.tidyverse.org/>
- <https://www.tidymodels.org/>
- <https://education.rstudio.com/learn/>
- <https://www.r-project.org/help.html>
- <https://hour.ine.pt/>



Informações finais



» Bibliografia

» Wickham H & Grolemund G (2017) R for Data Science. O'Reilly Media Inc., Sebastopol.

URL: <https://r4ds.had.co.nz/>

» Wickham H, Çetinkaya-Rundel M & Grolemund G (2023) R for Data Science. O'Reilly Media Inc., Sebastopol. O'Reilly Media Inc., Sebastopol.

URL: <https://r4ds.hadley.nz/>

