INSTITUTO NACIONAL DE ESTATÍSTICA
STATISTICS PORTUGAL

R para Ciência dos Dados - II

Primeira Parte

João Lopes e Pedro Sousa

Março 2026

PRR Plano de Recuperação e Resiliência
REPÚBLICA PORTUGUESA
Financiado pela União Europeia NextGenerationEU
CCD INE Capacitação em Ciência dos Dados

Programa

Programa

- **Transformação dos dados**
- **Exploração dos dados**
- **Modelação**
- Relatórios e apresentações
- Comunicação

Programa

- **Transformação dos dados**
  - Vetores numéricos
  - Fatores
  - Vetores lógicos
- **Exploração dos dados**
  - Variação
  - Valores em falta
  - Covariação
  - Padrões e Modelos
- **Modelação**
  - Construir modelo simples
  - Construir modelo com workflow()
  - Construir vários modelos com workflow()

Recapitulação

» Esquema geral

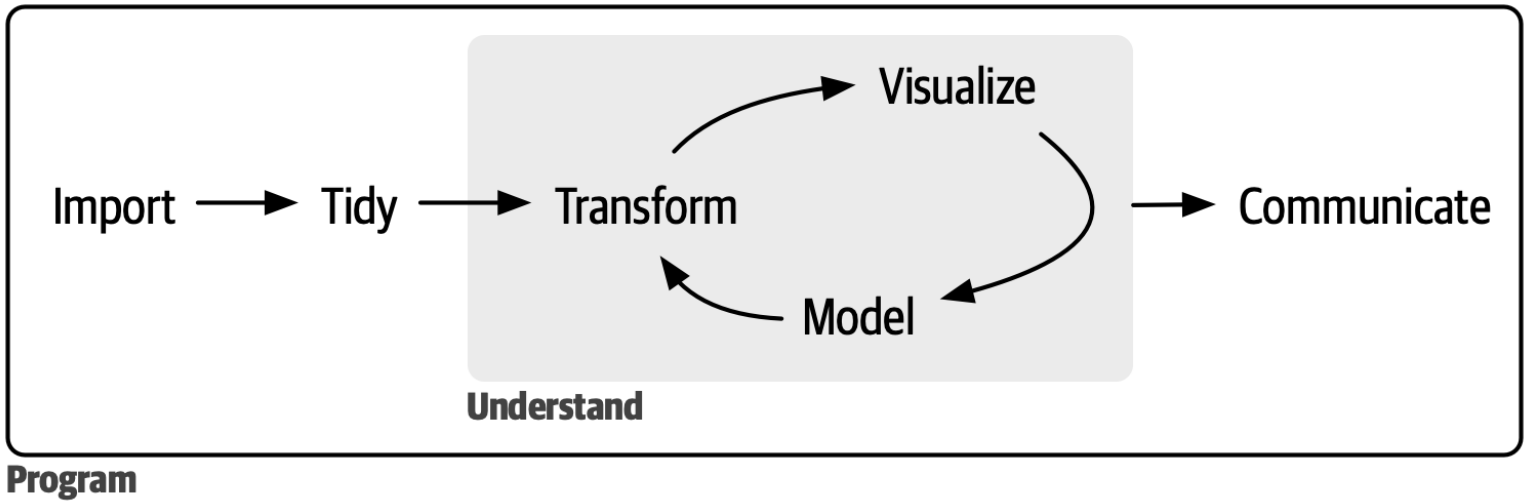

H. Wickham M. Çetinkaya-Rundel & G. Grolemund (2023)

https://r4ds.hadley.nz/

https://tidyverse.org/

Instituto Nacional de Estatística
Statistics Portugal
PRR Plano de Recuperação e Resiliência
República Portuguesa
Financiado pela União Europeia NextGenerationEU
CCDINE Capacitação em Ciência dos Dados

Dia 1 - Transformação

Dia 1 - Transformação

- **Vetores numéricos** → 09:30 - 11:00
  - Contagens (c/ exercícios) 11:15 - 12:30
  - Transformações numéricas (c/ exercícios)
  - Transformações genéricas (c/ exercícios)
  - Estatísticas descritivas (c/ exercícios)
- **Fatores** → 14:00 - 15:00
  - Operações básicas
  - Base de dados gss_cat (c/ exercícios)
  - Alterar ordem dos fatores (c/exercícios)
  - Alterar os fatores (c/ exercícios)
- **Vetores lógicos** → 15:15 - 17:00
  - Comparações (c/ exercícios)
  - Álgebra booleana (c/ exercícios)
  - Sumarização (c/ exercícios)
  - Transformações condicionais (c/ exercícios)

Instituto Nacional de Estatística
Statistics Portugal
PRR Plano de Recuperação e Resiliência
República Portuguesa
Financiado pela União Europeia NextGenerationEU
CCD INE Capacitação em Ciência dos Dados

Recapitulação

» Pacote **dplyr**

- `filter()` Selecionar linhas (i.e. observações);
- `arrange()` Ordenar linhas (i.e. observações);
- `select()` Selecionar colunas (i.e. variáveis);
- `mutate()` Criar novas colunas (i.e. variáveis);
- `summarize()` Calcular estatísticas descritivas.
- `group_by()` Criar grupos de observações para manipulação.

https://dplyr.tidyverse.org/

Recapitulação

» Pacote dplyr

```
library("tidyverse")

?diamonds

diamonds |>                                   #use data "diamonds"
  select(price, carat, cut) |>                #select "price", "carat" and "cut"
  filter(carat < 3) |>                        #filter for smaller diamonds
  mutate(lprice = log10(price)) |>            #create variable "lprice"
  group_by(cut) |>                            #group by "cut"
  sumarize(
    mean_lprice = mean(lprice)                #calculate mean of "lprice"
    mean_carat = mean(carat)                  #calculate mean of "carat"
  ) |>
  arrange(desc(mean_lprice))                  #arrange by "mean_lprice"
```

PRR Plano de Recuperação e Resiliência
REPÚBLICA PORTUGUESA
Financiado pela União Europeia NextGenerationEU
CCDLINE Capacitação em Ciência dos Dados

Recapitulação

» Pacote **dplyr**

```
# A tibble: 5 × 3
  cut       mean_lprice mean_carat
  <ord>           <dbl>      <dbl>
1 Fair             3.51      1.03
2 Premium          3.45      0.889
3 Good             3.41      0.847
4 Very Good        3.39      0.806
5 Ideal            3.32      0.702
```

PRR Plano de Recuperação e Resiliência
REPÚBLICA PORTUGUESA
Financiado pela União Europeia NextGenerationEU
CCDLINE Capacitação em Ciência dos Dados

Dia 2 - Exploração

INSTITUTO NACIONAL DE ESTATÍSTICA
STATISTICS PORTUGAL

Dia 2 - Exploração

- **Variação** → 09:30 - 11:00
  - Valores típicos (c/ exercícios)
  - Valores invulgares
- **Valores em falta** → 11:15 - 12:30
  - Explícitos (c/ exercícios)
  - Implícitos (c/ exercícios)
  - Fatores e grupos vazios
- **Covariação** → 14:00 - 16:00
  - Uma categórica e uma numérica (c/ exercícios)
  - Duas categóricas (c/ exercícios)
  - Duas numéricas (c/ exercícios)
- **Padrões e modelos** → 16:15 - 17:00

PRR Plano de Recuperação e Resiliência
REPÚBLICA PORTUGUESA
Financiado pela União Europeia NextGenerationEU
CCD INE Capacitação em Ciência dos Dados

Recapitulação

» Pacote `ggplot2`

- Data;
- Aesthetic mapping (**aes**);
- Geometric object (**geom**);
- Statistical transformation (**stat**);
- Scale;
- Themes.

https://ggplot2.tidyverse.org/

Recapitulação

» Pacote ggplot2

```
set.seed(1984)

diamonds |>                                          #use data "diamonds"
  filter(carat < 3) |>                               #filter for smaller diamonds
  slice_sample(n=500, by=cut) |>                     #sample for 500 obs per "cut"
  ggplot(aes(x=carat, y=price, color=cut)) +         #aesthetics mapping
  geom_point(alpha=0.1, size=1) +                    #geometric object
  stat_smooth(                                       #statistical transformation
    method="lm",
    formula="y ~ x + I(x^2) + I(x^3)",
    se=FALSE) +
  scale_x_continuous(trans="log10") +                #scale for x-axis
  scale_y_continuous(trans="log10") +                #scale for y-axis
  labs(x="Weight", y="Price", color="Cut") +         #scale for labels
  theme_minimal()                                    #change theme
```

Recapitulação

» Pacote **ggplot2**

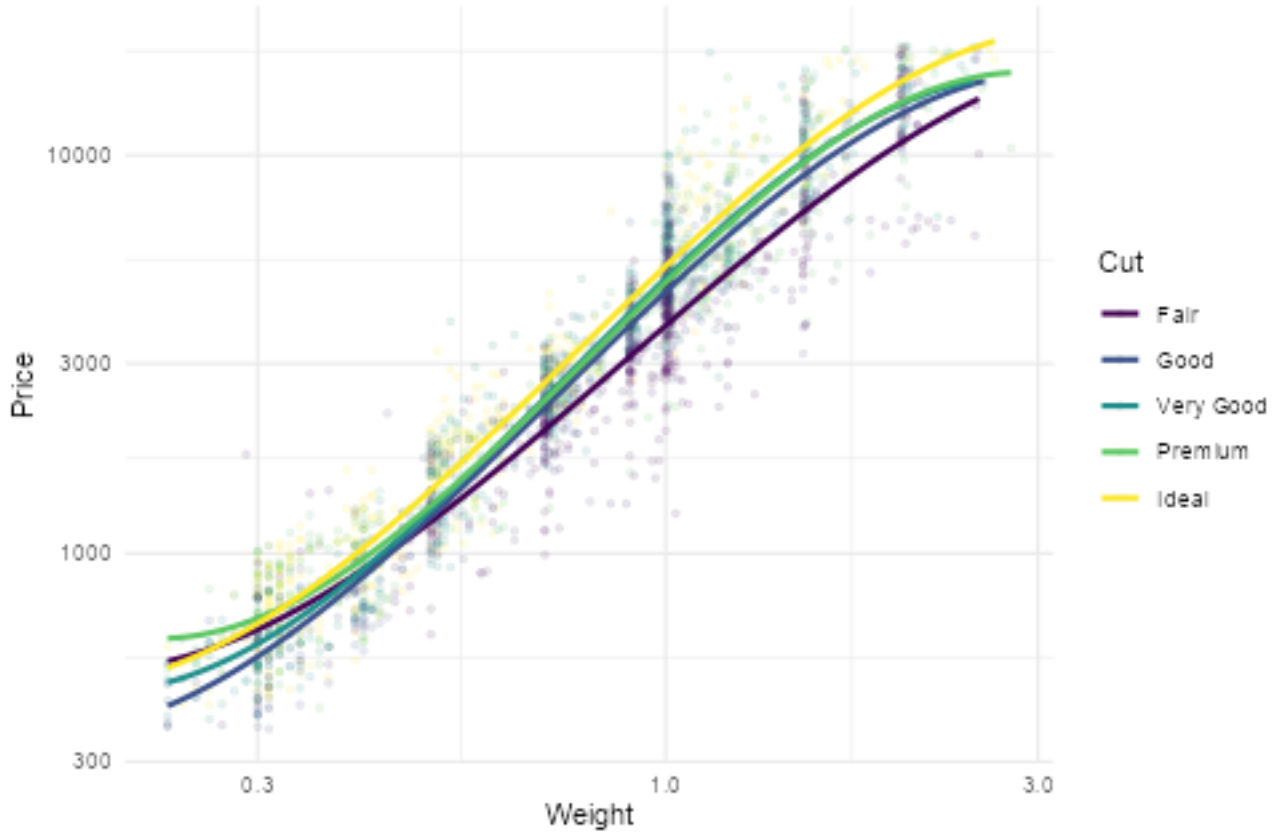

Dia 3 - Modelação

Dia 3 - Modelação

- **Construir modelo simples** → 09:30 - 11:00
  - Explorar dados
  - Ajustar modelo (c/ exercícios)
  - Usar modelo para previsão (c/ exercícios)
- **Construir modelo com *workflow*** → 11:15 - 12:30
  - Explorar dados
  - Dividir dados
  - Criar workflow (c/ exercícios)
  - Ajustar modelo (c/ exercícios)
  - Avaliar modelo (c/ exercícios)
- **Construir vários modelos com *workflow*** → 14:00 - 15:00
  - Explorar dados 15:15 - 17:00
  - Dividir dados
  - Criar *workflow* e ajustar modelo 1 (c/ exercícios)
  - Criar *workflow* e ajustar modelo 2 (c/ exercícios)
  - Avaliar o melhor modelo (c/ exercícios)

Instituto Nacional de Estatística
Statistics Portugal
PRR Plano de Recuperação e Resiliência
República Portuguesa
Financiado pela União Europeia NextGenerationEU
CCD INE Capacitação em Ciência dos Dados

Recapitulação

» Pacote **`stats`**: funções **`lm()`** e **`summary()`**

- Data;
- Formula (e.g. `formula()`);
- Fit model (eg. `lm()`, `glm()`, `aov()`, …);
- Extract parametes (eg. `residuals()`, `predicted()`, `coef()`, …);
- Testing assumptions (eg. `plot()`, …);
- Evaluate model (eg. `summary()`, `AIC()`, `logLik()`, …).

https://cran.r-project.org/doc/manuals/r-patched/packages/stats/refman/stats.html

https://rpubs.com/abigailpayne/743827

Instituto Nacional de Estatística
Statistics Portugal
PRR Plano de Recuperação e Resiliência
República Portuguesa
Financiado pela União Europeia NextGenerationEU
CCD INE Capacitação em Ciência dos Dados

Recapitulação

» Pacote **stats**: funções **lm()** e **summary()**

```
diamonds2 <- diamonds |>                          #use data "diamonds"
  filter(
    (x > 0) & (y > 0 & y < 20) & (z > 0 & z < 10), #filter out outliers
    carat < 3) |>                                 #filter out big diamonds
  slice_sample(n=1000) |>                         #sample for 1000 observations
  select(price, carat, cut) |>                    #select "price", "carat" and "cut"
  mutate(
    lprice = log10(price),                        #create variable "lprice"
    lcarat = log10(carat),                        #create variable "lcarat"
    fct_cut = factor(cut, ordered=FALSE)          #make variable "cut" into factor
  )

mod1 <- formula("lprice ~ lcarat + fct_cut")      #specify model
res1 <- lm(mod1, data=diamonds2)                  #fit model to data
summary(res1)                                     #get summary
```

Recapitulação

» Pacote **stats**: funções **lm()** e **summary()**

```
Residuals:
     Min       1Q   Median       3Q      Max
-0.33696 -0.06961  0.00255  0.07358  0.36898

Coefficients:
                 Estimate Std. Error t value Pr(>|t|)
(Intercept)       3.56450    0.02020 176.449  < 2e-16 ***
lcarat            1.70134    0.01384 122.938  < 2e-16 ***
fct_cutGood       0.07818    0.02347   3.331 0.000896 ***
fct_cutVery Good  0.09259    0.02164   4.279 2.06e-05 ***
fct_cutPremium    0.08857    0.02144   4.131 3.91e-05 ***
fct_cutIdeal      0.12437    0.02111   5.891 5.24e-09 ***

Multiple R-squared:  0.9396,  Adjusted R-squared:  0.9393
F-statistic:  3093 on 5 and 994 DF,  p-value: < 2.2e-16
```

Recapitulação

» Pacote `performance`

MLR.1 O modelo é linear nos parâmetros;

MLR.2 Amostra aleatória (e.g. não há outliers, valores omissos aleatórios);

MLR.3 Não há multicolinearidade entre preditores;

MLR.4 Erro com valor esperado zero dado qualquer valor dos preditores;

MLR.5 Erro com variância constante dado qualquer valor dos preditores;

MLR.6 Erro é independente dos preditores e tem distribuição normal.

Wooldridge J, Introductory Econometrics: A Modern Approach, 7 ed. Thomson

Instituto Nacional de Estatística
Statistics Portugal
PRR Plano de Recuperação e Resiliência
República Portuguesa
Financiado pela União Europeia NextGenerationEU
CCD INE Capacitação em Ciência dos Dados

Recapitulação

» Pacote **performance**

```
library("performance")

check_model(res1, check=c(
  #MLR.1 The population model is linear in the parameters
  "linearity",
  #MLR.3 No multicollinearity between predictors
  "vif",
  #MLR.5 The error has constant variance given any values of the parameters
  "homogeneity",
  #MLR.6 The error is independent of the predictors and is normally distributed
  "qq"
))
```

PRR Plano de Recuperação e Resiliência
REPÚBLICA PORTUGUESA
Financiado pela União Europeia NextGenerationEU
CCDLINE Capacitação em Ciência dos Dados

Recapitulação

» Pacote **performance**

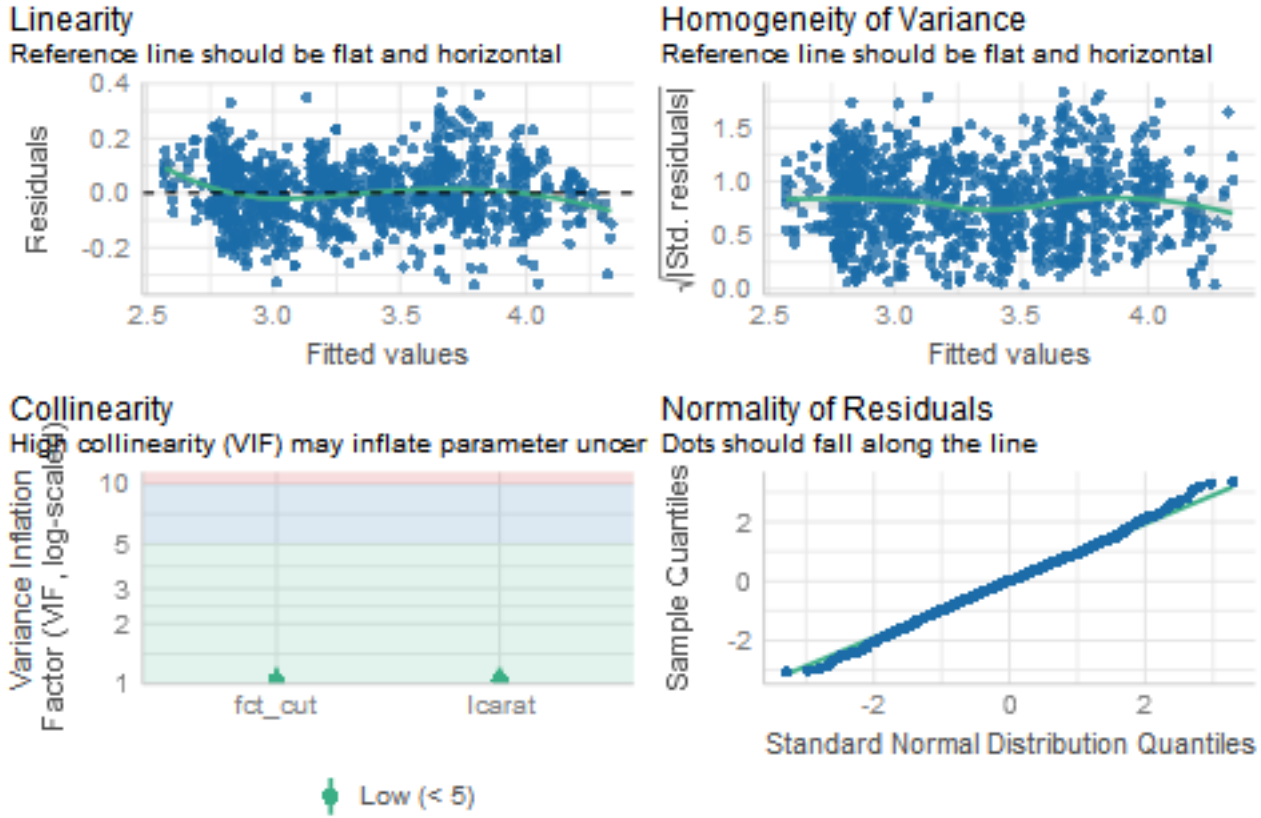

Modelos

» Regressão linear simples

```
beta0 <- -1.6
beta1 <- 0.03
tb_lm <- tibble(
  x = runif(20, min=18, max=60),
  y = beta0 + beta1*x + rnorm(20, mean=0, sd=0.1)
)

res_lm <- lm(y ~ x, data=tb_lm)

tb_lm |>
  mutate(preds = predict(res_lm), resids = residuals(res_lm)) |>
  ggplot(aes(x=x, y=y)) + geom_point() +
  stat_smooth(method="lm", formula="y ~ x", se=FALSE, color="blue") +
  geom_segment(aes(xend=x, yend=preds), color="red")
```

Modelos

» Regressão linear simples

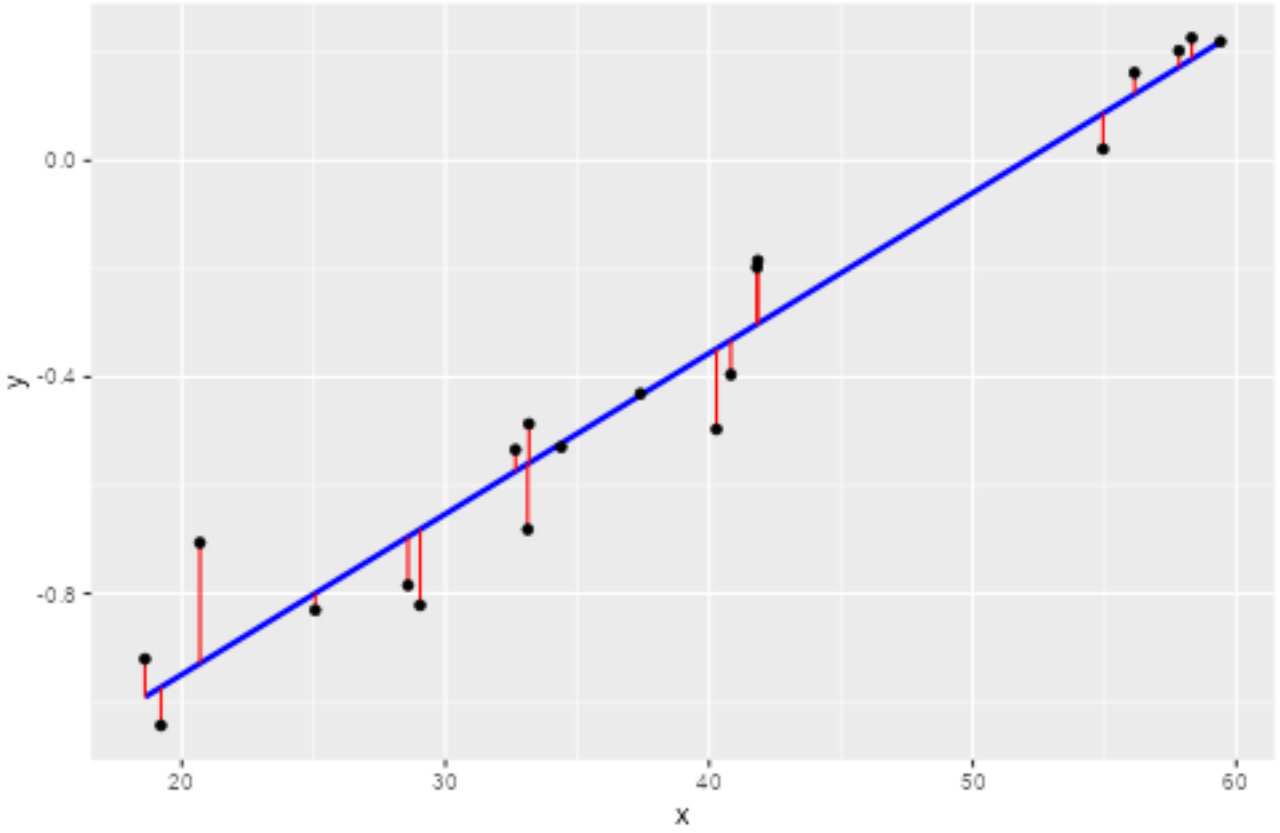

Modelos

» Regressão linear múltipla

```
beta0 <- -1.6; beta1 <- 0.03; beta2 <- -1.0
tb_lm2 <- tibble(
  x1 = runif(20, min=18, max=60),
  x2 = rbinom(20, size=1, prob=0.5),
  y = beta0 + beta1*x1 + beta2*x2 + rnorm(20, mean=0, sd=0.1)
) |>
  mutate(x2 = factor(x2))
res_lm2 <- lm(y ~ x1 + x2, data=tb_lm2)
v1 <- res_lm2$coef
tb_lm2 |>
  mutate(preds = predict(res_lm2), resids = residuals(res_lm2)) |>
  ggplot(aes(x=x1, y=y, color=x2)) + geom_point() +
  geom_abline(slope=v1[2], intercept=v1[1], color="#F8766D") +
  geom_abline(slope=v1[2], intercept=sum(v1[c(1, 3)]), color="#00BFC4") +
  geom_segment(aes(xend=x1, yend=preds), color="red")
```

» Regressão linear múltipla

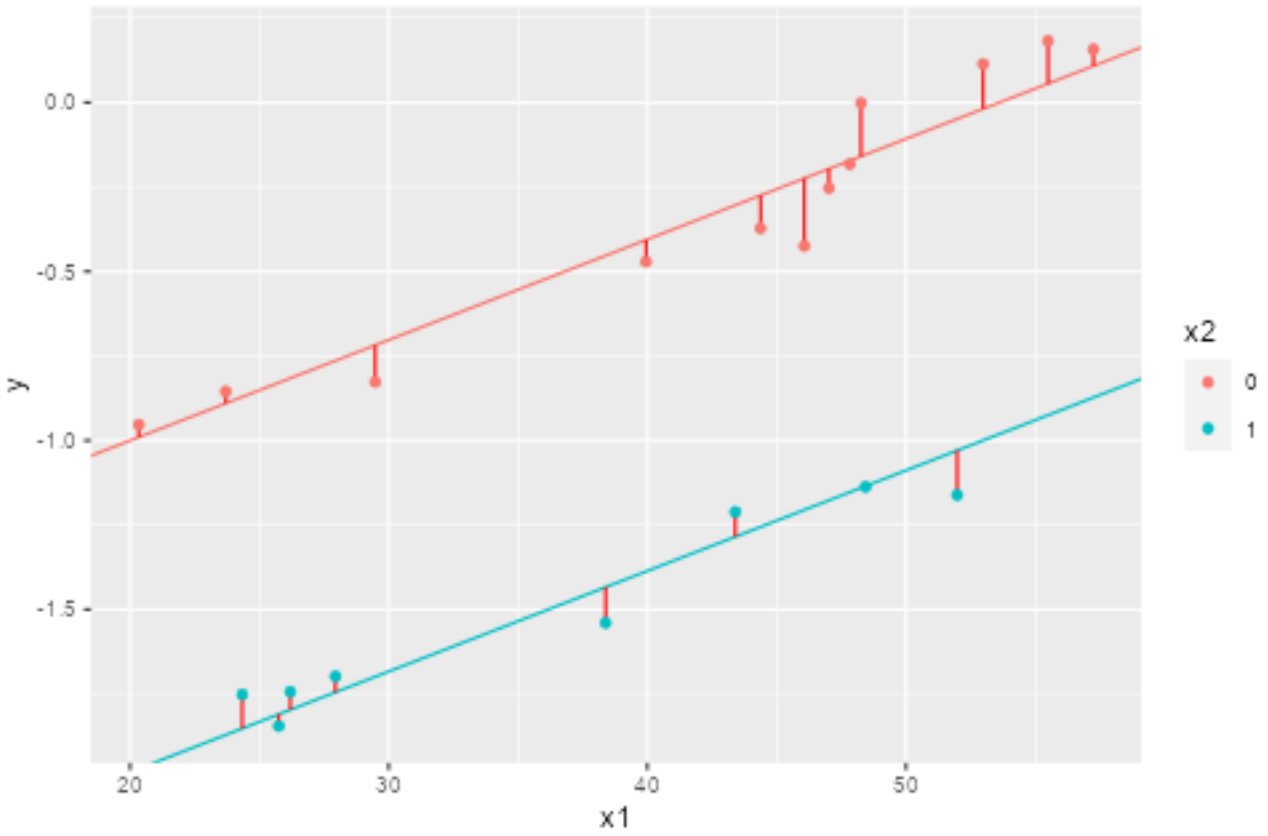

Instituto Nacional de Estatística
Statistics Portugal
PRR Plano de Recuperação e Resiliência
República Portuguesa
Financiado pela União Europeia NextGenerationEU
CCD INE Capacitação em Ciência dos Dados

Modelos

» Regressão logística

```
beta0 <- -1.6
beta1 <- 0.03
tb_glm <- tibble(
  x = runif(20, min=18, max=60),
  pi_y = exp(beta0 + beta1*x)/(1 + exp(beta0 + beta1*x)),
  y = rbinom(20, size=1, prob=pi_y)
)
res_glm <- glm(y ~ x, binomial(link="logit"), data=tb_glm)
tb_glm |>
  mutate(preds = predict(res_glm, type="resp"), resids = residuals(res_glm)) |>
  ggplot(aes(x=x, y=y)) + geom_point() +
  stat_smooth(method="glm", formula="y ~ x", se=FALSE, color="blue",
    method.args=list(family="binomial")) +
  geom_segment(aes(xend=x, yend=preds), color="red") +
  geom_hline(yintercept=c(0.4, 0.5 , 0.6), linetype="dashed", color="gray")
```

Modelos

» Regressão logística

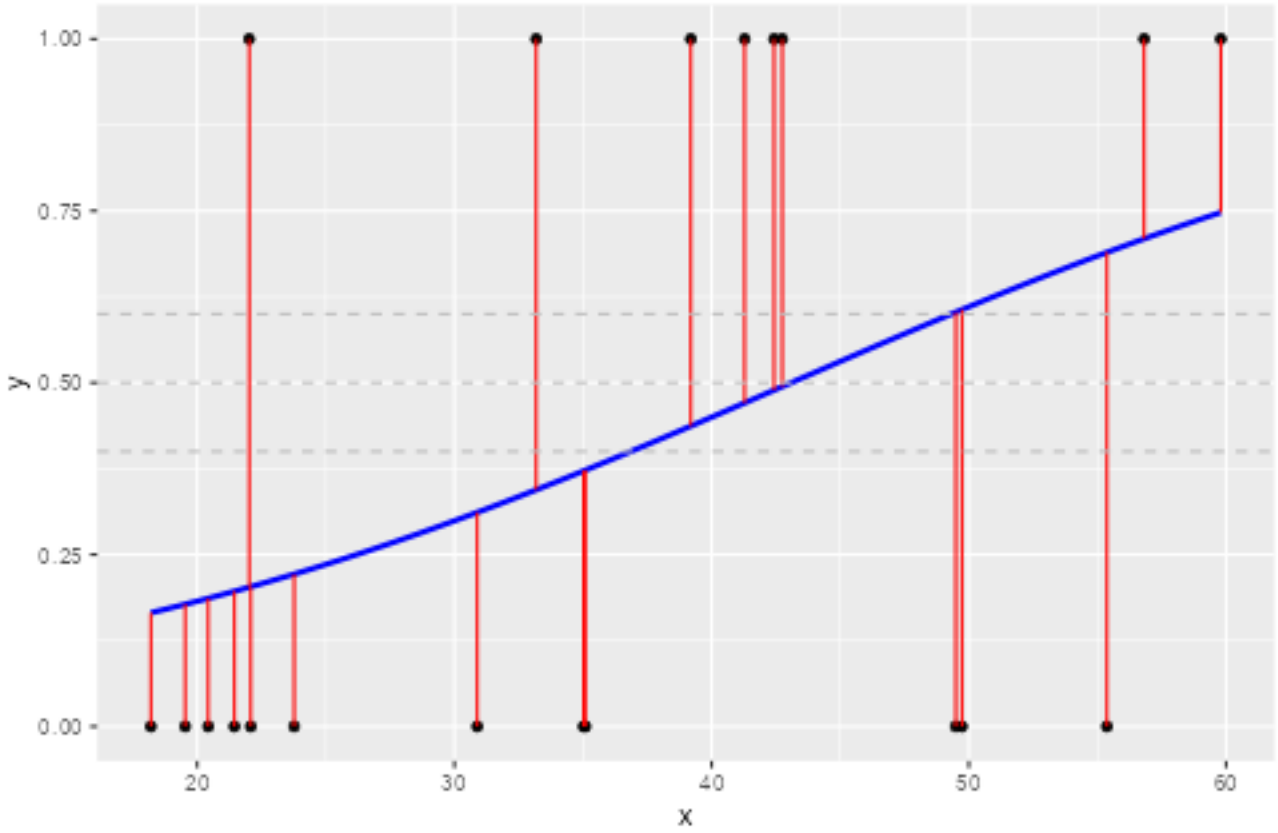

Modelos

» Árvores de decisão

```
library("rpart")

tb_rf <- tibble(
  x1 = ceiling(runif(20, min=0, max=4)),
  x2 = ceiling(runif(20, min=0, max=2)),
  x3 = ceiling(runif(20, min=0, max=2)),
  pi_y = exp(x1 - (x2 + x3))/(1 + exp(x1 - (x2 + x3))),
  y = rbinom(20, size=1, prob=pi_y)
) |> mutate(across(c(x1:x3, y), as.factor))
res_rd <- rpart(y ~ x1 + x2 + x3, data=tb_rf, method="class",
  control = rpart.control(minsplit=5))

plot(res_rd, branch=0, margin=0.02, branch.lwd=2, branch.col="blue")
text(res_rd, minlength=2, use.n=TRUE, fancy=TRUE, fwidth=1.5, fheight=1,
  cex=0.8, font=2)
```

» Árvores de decisão

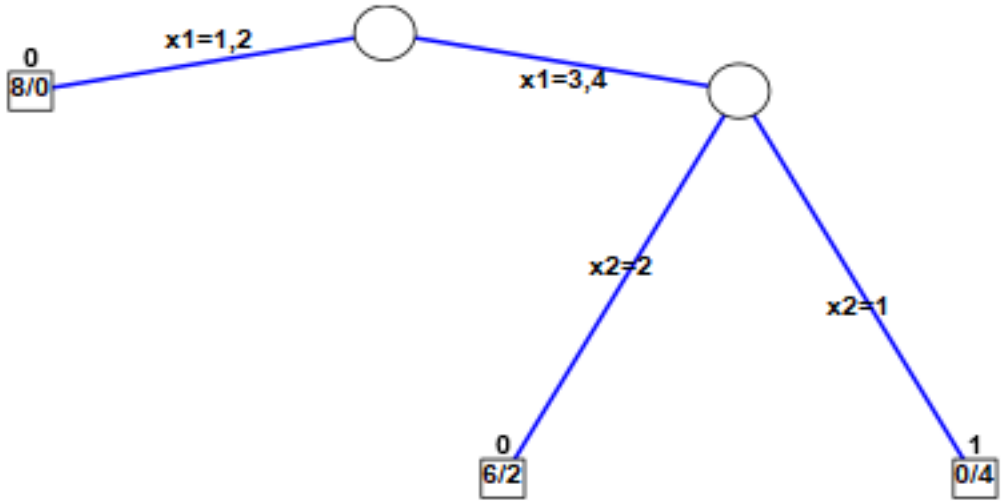

Instituto Nacional de Estatística
Statistics Portugal
PRR Plano de Recuperação e Resiliência
República Portuguesa
Financiado pela União Europeia NextGenerationEU
CCD Capacitação em Ciência dos Dados

Avaliação de modelos

» Visão Geral

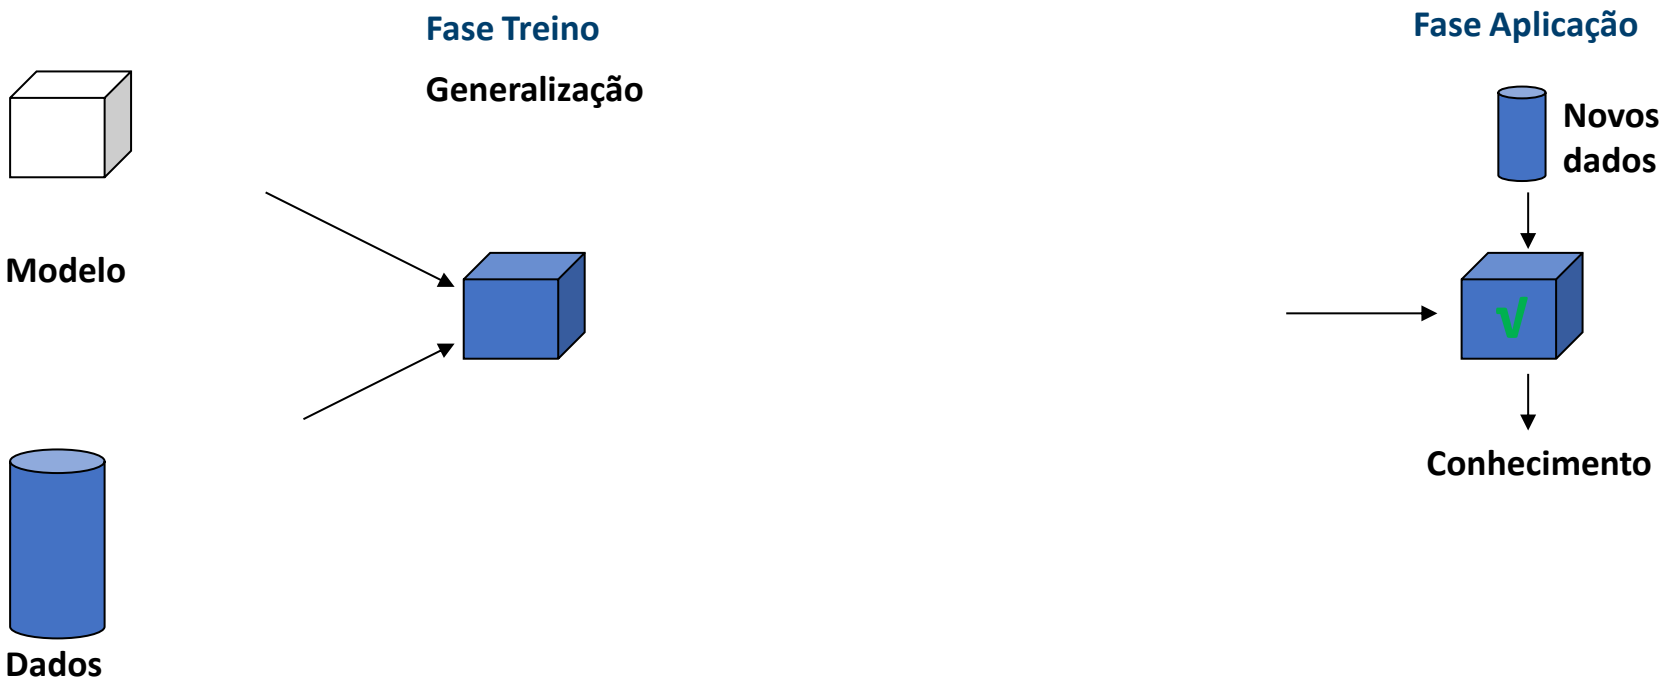

Avaliação de modelos

» Visão Geral

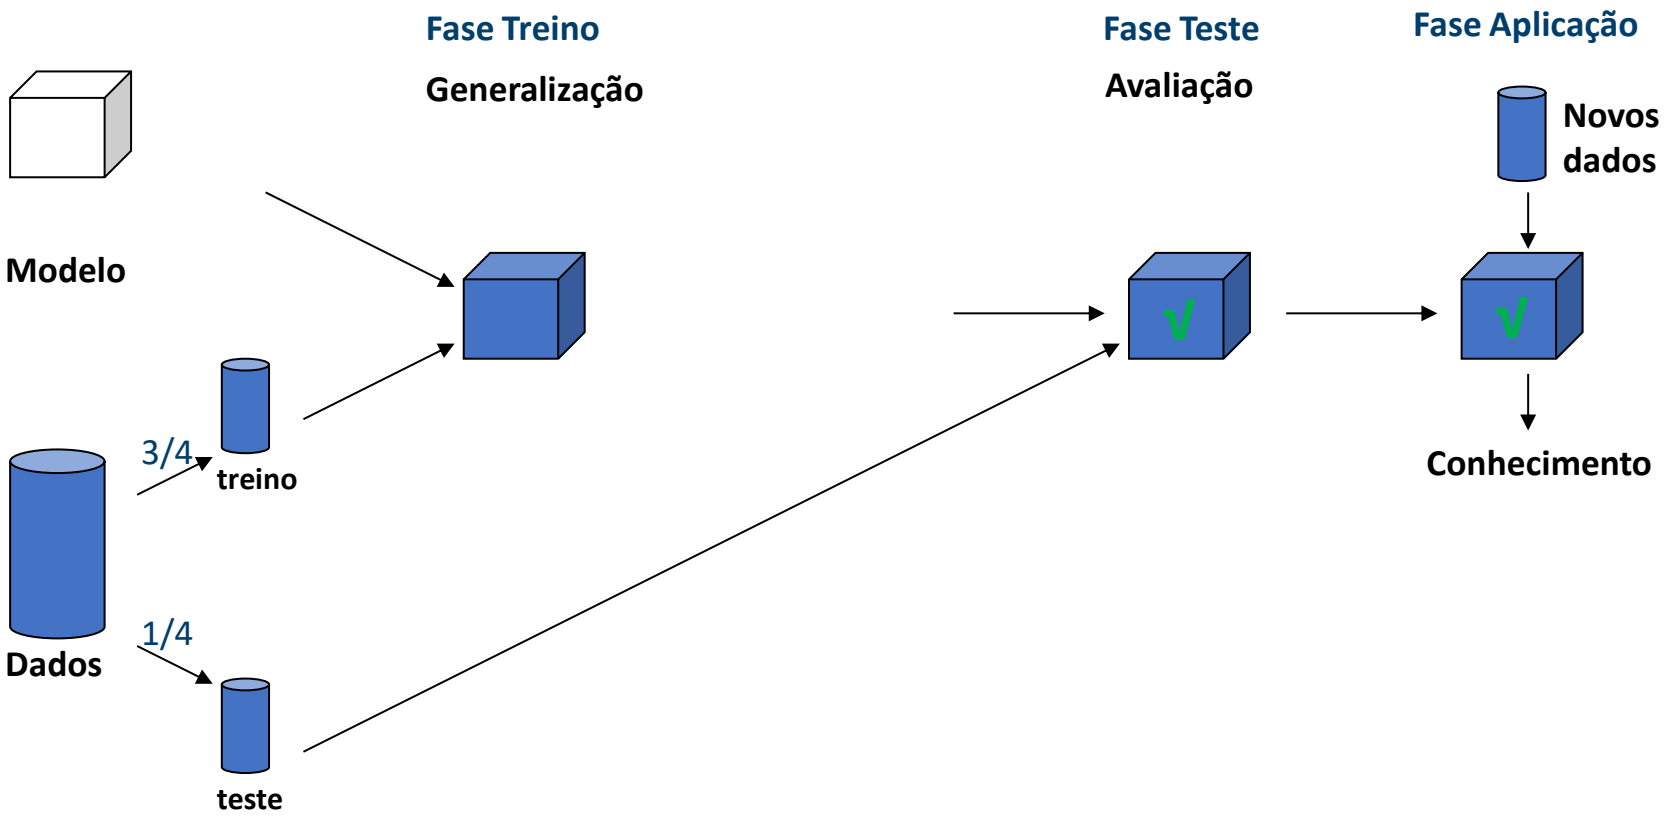

Avaliação de modelos

» Visão Geral

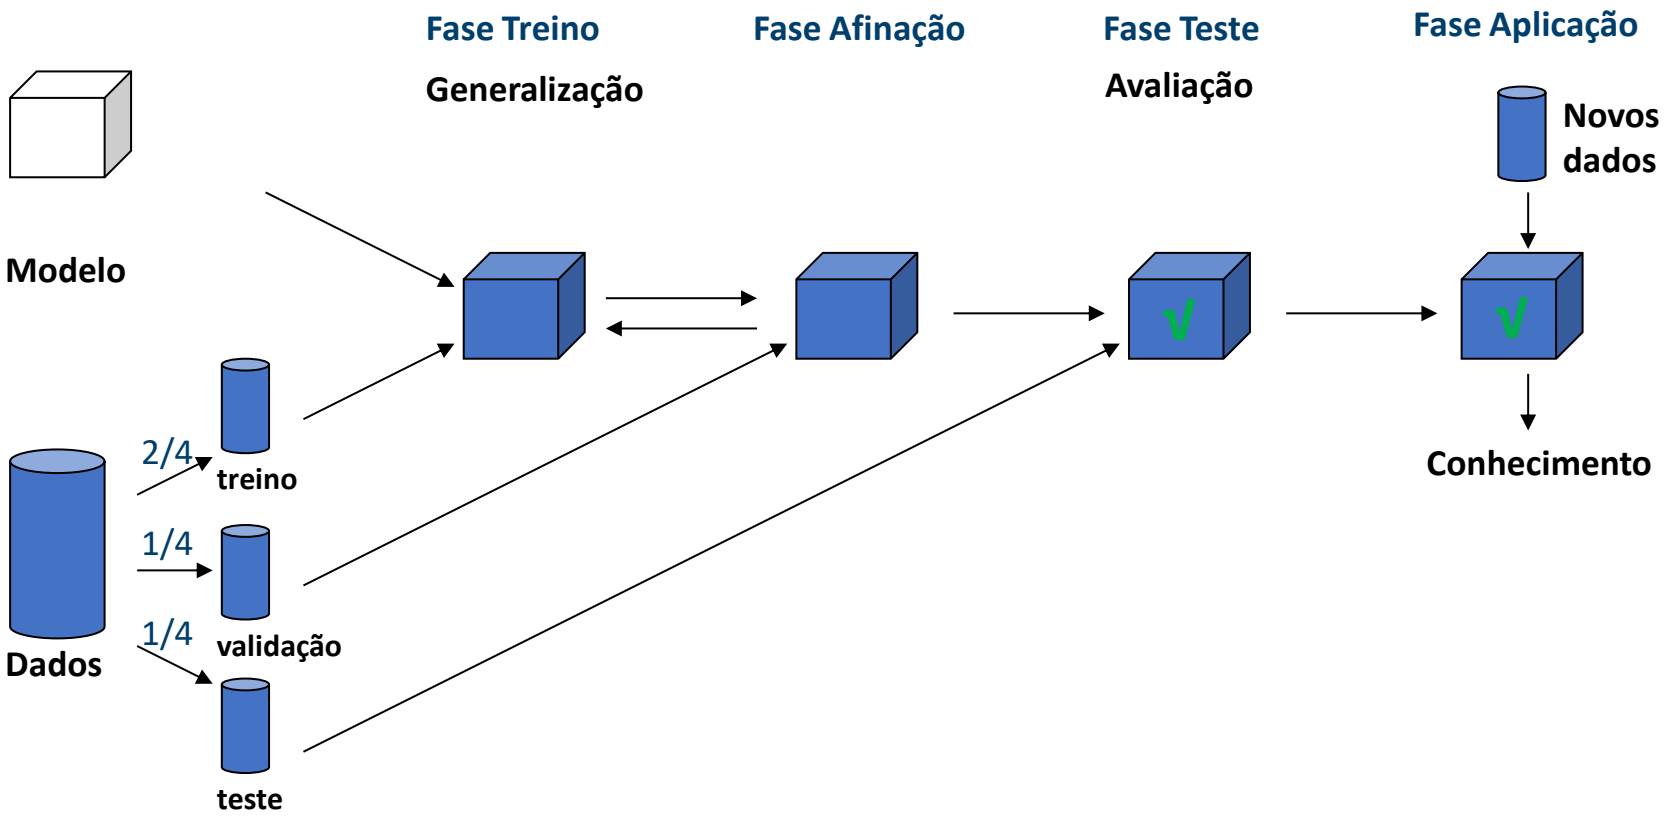

Avaliação de modelos

» Métricas: variável contínua

Root Mean Square Error (RMSE)

$$\text{RMSE} = \sqrt{\sum_{i=1}^{n} (\hat{y} - y)^2 / n}$$

Mean Absoute Error (MAE)

$$\text{MAE} = \sum_{i=1}^{n} |\hat{y} - y| / n$$

Avaliação de modelos

» Métricas: variável categórica (binária)

True Positive Rate (Sensitivity)
$= \mathrm{TP}/\mathrm{P}$

False Positive Rate (1 - Specificity)
$= \mathrm{FP}/\mathrm{N} = 1 - \mathrm{TN}/\mathrm{N}$

Trade-off: Sensitivity vs. Specificity

	Predicted (p = 0.50)		
Real	**Positive**	**Negative**	
Positive	**True P.**	False N.	P.
Negative	False P.	**True N.**	N.

Avaliação de modelos

» Métricas: variável categórica (binária)

True Positive Rate (Sensitivity)
$= \mathrm{TP}/\mathrm{P}$

False Positive Rate (1 - Specificity)
$= \mathrm{FP}/\mathrm{N} = 1 - \mathrm{TN}/\mathrm{N}$

Trade-off: Sensitivity vs. Specificity

	Predicted (p = 0.50)		
Real	**Positive**	**Negative**	
Positive	**True P.**	False N.	P.
Negative	False P.	**True N.**	N.

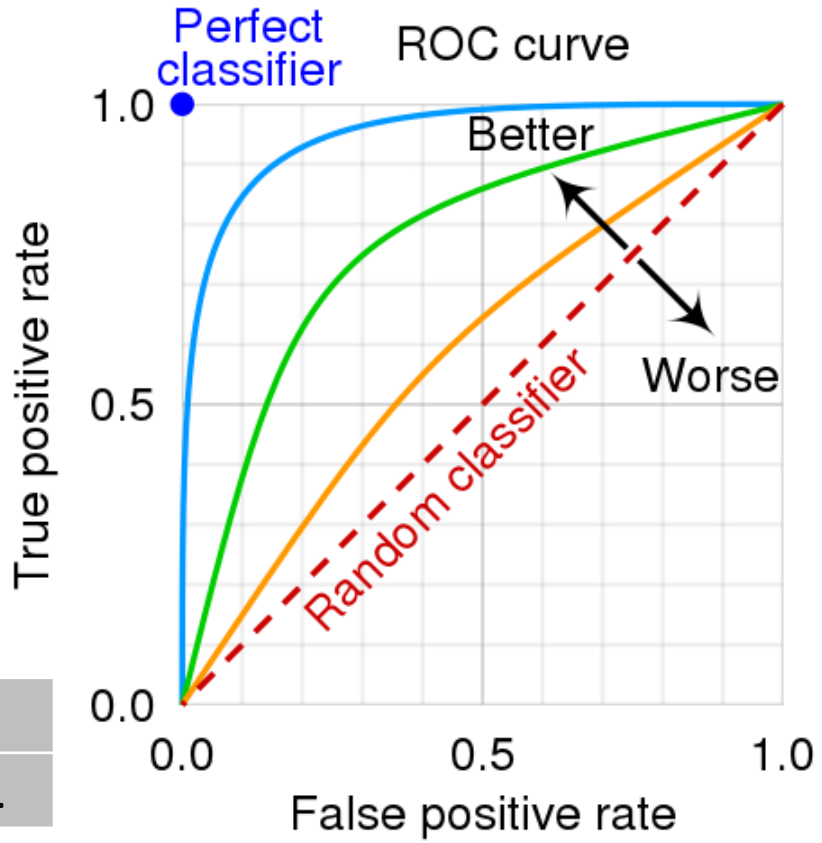

M. Thoma (2018)

Informações finais

Informações finais

» Gestão de projectos

- Estrutura de pastas;
- Ficheiro README (e nomeação de ficheiros);
- Controlo de versões (e.g. github.com, git.ine.pt).

Informações finais

» Estrutura de pastas

```
C:.
└───Projects
    ├───2023
    │   ├───2023.01.01_ProjectName
    │   └───2023.04.01_ProjectName
    ├───2024
    │   ├───2024.02.29_ProjectName
    │   └───2024.12.25_ProjectName
    └───2025
        ├───2025.03.05_ProjectName
        └───2025.10.31_DSR2025
            ├───bin
            ├───data
            ├───docs
            ├───media
            └───results
                ├───1.transform
                ├───2.exploratory
                └───3.modeling
```

Instituto Nacional de Estatística
Statistics Portugal
PRR Plano de Recuperação e Resiliência
República Portuguesa
Financiado pela União Europeia NextGenerationEU
CCDLINE Capacitação em Ciência dos Dados

Informações finais

» Ficheiro README

```
#autor:      Joao Sollari Lopes
#local:      INE, Lisboa
#criado:     31.12.2025
#modificado: 29.02.2026

+bin
  |0.examples.r                          #exemplos para recapitulacao
  |0.install_packages.r                  #instalar pacotes necessarios
  |1.transform.r                         #transformacao de dados
  |2.exploration.r                       #exploração de dados
  |3.modelling.r                         #modelacao de dados
+docs
  |DSR-II2026_program.pdf                #programa
  |DSR-II2026_slides.pdf                 #slides [versao final]
  |DSR-II2026_slides_20260101.pptx       #slides [v2026-01-01]
  |DSR-II2026_slides_20260229.pptx       #slides [v2026-02-29]
+results
  +1.tranform                            #resultados de "1.transform.r"
  +2.exploration                         #resultados de "2.exploration.r"
  +3.modelling                           #resultados de "3.modelling.r"
README.txt                               #Este ficheiro
```

Instituto Nacional de Estatística
Statistics Portugal
PRR Plano de Recuperação e Resiliência
República Portuguesa
Financiado pela União Europeia NextGenerationEU
CCD INE Capacitação em Ciência dos Dados

INSTITUTO NACIONAL DE ESTATÍSTICA
STATISTICS PORTUGAL

Informações finais

» Controlo de versões

4 bin/3.modelling.r

```diff
@@ -2,7 +2,7 @@
 #local:      INE, Lisboa
 #Rversion:   4.3.1
 #criado:     17.07.2023
-#modificado: 18.04.2024
+#modificado: 16.09.2024

 # 0. INDEX
 {
@@ -344,7 +344,7 @@ lr_res |>
   scale_x_log10(labels = scales::label_number())

 lr_res |>
-  show_best("roc_auc", n = 5) |>
+  show_best(metric = "roc_auc", n = 5) |>
   arrange(penalty)

 lr_best <-
```

PRR Plano de Recuperação e Resiliência
REPÚBLICA PORTUGUESA
Financiado pela União Europeia NextGenerationEU
CCDINE Capacitação em Ciência dos Dados

Informações finais

» Comunidade R

- https://www.r-project.org/
- https://www.tidyverse.org/
- https://www.tidymodels.org/

- https://education.rstudio.com/learn/
- https://www.r-project.org/help.html

- https://hour.ine.pt/

Informações finais

» Bibliografia

» Wickham H & Grolemund G (2017) R for Data Science. O'Reilly Media Inc., Sevastopol.
URL: https://r4ds.had.co.nz/

» Wickham H, Çetinkaya-Rundel M & Grolemund G (2023) R for Data Science. O'Reilly Media Inc., Sevastopol. O'Reilly Media Inc., Sevastopol.
URL: https://r4ds.hadley.nz/